

LAPORAN DSC MCF ITB 2026

Data Science Competition - MCF ITB 2026

Studi Kasus: Prediksi Klaim Asuransi Kesehatan Individu - AXA Financial Indonesia



TIM CUNGPRET

- 1. Ferliyana Ronnan**
- 2. Ababil Khoreul Imam**
- 3. Vierico Ventora**

**DATA SCIENCE COMPETITION
MATHEMATICAL CHALLENGE FESTIVAL
INSTITUT TEKNOLOGI BANDUNG
2026**

LEMBAR PERNYATAAN ORSINALITAS DAN DEKLARASI PENGUNAAN KECERDASAN BUATAN GENERATIF

Kami yang bertanda tangan di bawah ini:

Nama Tim : Cungpret
Nama Ketua Tim : Ferliyana Ronnan
Nama Anggota Tim1 : Ababil Khoerul Imam
Nama Anggota Tim 2 : Vierico Ventora

Dengan ini menyatakan bahwa laporan yang kami sertakan dalam perlombaan Data Science Competition MCF ITB 2026 merupakan hasil karya orisinal, tidak mengandung plagiarisme dari pihak manapun, dan belum pernah diikutsertakan dalam perlombaan lain.

Kami juga mendeklarasikan penggunaan kecerdasan buatan generatif (Generative AI) dalam proses penyusunan laporan ini. Model kecerdasan buatan generatif yang digunakan adalah sebagai berikut:

Nama Model: ChatGPT-4o (OpenAI), Claude (Anthropic)

Pengembang Model: OpenAI & Anthropic

Kami menggunakan model kecerdasan buatan generatif tersebut untuk keperluan berikut:

1. ChatGPT-4o (OpenAI) membantu merevisi tanda baca, tata bahasa, dan kejelasan penulisan pada laporan agar lebih rapi dan mudah dipahami;
2. Claude (Anthropic) membantu mempercepat proses eksplorasi eksperimen serta membantu proses debugging pada kode yang dibuat selama pengembangan model. Penggunaan model AI bersifat sebagai asisten teknis, sementara proses analisis data, perancangan eksperimen, pemilihan model, dan interpretasi hasil dilakukan oleh tim peserta.

Kami menyatakan bahwa seluruh keluaran model model kecerdasan buatan generatif yang digunakan telah melalui proses peninjauan, verifikasi, dan pengolahan ulang oleh tim. Seluruh isi laporan yang dikumpulkan merupakan hasil pemahaman, analisis, dan tanggung jawab kami sebagai peserta kompetisi.

Apabila di kemudian hari kami diketahui melanggar pernyataan ini, kami siap menerima konsekuensi yang telah ditetapkan oleh panitia MCF ITB 2026 berupa sanksi diskualifikasi

dari perlombaan ini. Demikian pernyataan ini dibuat dengan sebenarnya, untuk digunakan sebagaimana mestinya.

Surabaya, 12 Maret 2026

Yang menyatakan,

A handwritten signature in black ink, appearing to read 'Ferliyana Ronnan', with a stylized flourish at the end.

Ferliyana Ronnan

ABSTRAK

Studi ini membangun sistem prediksi data klaim asuransi kesehatan individu bagi AXA Financial Indonesia dengan memanfaatkan pendekatan ensemble machine learning. Data yang digunakan meliputi 4.096 polis aktif dan 4.627 klaim berstatus PAID dalam rentang 19 bulan (Januari 2024 - Juli 2025). Tiga algoritma dipadukan secara sinergis: Prophet untuk menangkap pola tren musiman, LightGBM guna memodelkan dependensi lag dan interaksi fitur non-linear, serta Seasonal Naive sebagai jangkar stabilitas baseline. Penentuan bobot ensemble dilakukan secara independen per target menggunakan skema inverse MAPE weighting, yang menghasilkan MAPE rata-rata 4,79% jauh lebih unggul dibandingkan Prophet saja (15,50%) maupun LightGBM saja (7,36%). Uji ablasi memperlihatkan bahwa fitur lag menyumbang kontribusi terbesar (+4,00% rata-rata Δ MAPE), disusul fitur siklus/cyclical (+3,74%) dan rolling statistics (+2,86%). Proyeksi untuk 17 bulan ke depan (Agustus 2025 - Desember 2026) mengindikasikan kondisi portofolio yang cukup stabil, dengan total klaim 2026 terannualisasi hanya mengalami pergeseran sebesar -0,1% relatif terhadap 2025, meski volatilitas musiman masih perlu diwaspadai khususnya di paruh pertama tahun.

DAFTAR ISI

LEMBAR PERNYATAAN ORSINALITAS DAN DEKLARASI PENGGUNAAN KECERDASAN BUATAN GENERATIF	ii
ABSTRAK	iv
DAFTAR ISI.....	v
DAFTAR GAMBAR.....	vii
DAFTAR TABEL	vii
BAB I PENDAHULUAN.....	8
1.1 Latar Belakang	8
1.2 Rumusan Masalah.....	8
1.3 Tujuan	8
BAB II METODOLOGI.....	9
2.1 Data	9
2.1.1 Sumber Data	9
2.1.2 Preprocessing & Winsorisasi.....	9
2.1.3 Feature Engineering.....	10
2.2 Model yang Digunakan	10
2.3 Arsitektur Ensemble & Validasi	11
2.3.1 Walk-Forward Validation.....	11
2.3.2 Bobot Ensemble & Progressive Weighting	11
2.3.3 Metrik Evaluasi (MAPE).....	11
2.3.4 Sensitivity Analysis Hyperparameter	11
2.3.5 Prediction Interval & Backtesting Coverage	11
BAB III HASIL DAN PEMBAHASAN	12
3.1 Eksplorasi Data Analysis (EDA).....	12
3.1.1 Distribusi Klaim	12

3.1.2 Analisis Demografis	12
3.1.3 Tren Bulanan	14
3.2 Machine Learning Training.....	15
3.2.1 Perbandingan MAPE Per Model	15
3.2.2 Dampak Feature Engineering - Ablasi	16
3.2.3 Bobot Ensemble & Feature Importance	16
3.2.4 Sensitivity Analysis Hyperparameter	17
3.3.2 Backtesting Empirical Coverage	18
2.3.3 Ringkasan Prediksi 2026 per Kuartal	18
3.3.4 Analisis Tren & Perbandingan 2025 vs 2026	19
BAB IV PENUTUP	20
4.1 Kesimpulan.....	20
4.2 Saran.....	20
4.2.1 Cadangan Teknis 2026	20
4.2.2 Mitigasi Risiko Demografis.....	21
4.2.3 Optimasi Biaya Layanan melalui Manajemen Length of Stay	21
4.2.4 Perencanaan Kapasitas Musiman	21
4.3 Limitasi dan Pengembangan Ke Depan	22
DAFTAR PUSTAKA.....	23
LAMPIRAN.....	24
Lampiran A - Prediksi Lengkap Agustus 2025 - Desember 2026	24
Lampiran B - Ringkasan Model & Hyperparameter	25

DAFTAR GAMBAR

<i>Gambar 3.1. Boxplot nominal klaim per kelompok umur</i>	13
<i>Gambar 3.2. Boxplot nominal klaim per tipe layanan (IP/ODC/ODS/OP).....</i>	14
<i>Gambar 3.3. Tren frekuensi klaim bulanan (Jan 2024 - Jul 2025).....</i>	14
<i>Gambar 3.4. Tren total klaim bulanan (Jan 2024 - Jul 2025)</i>	15
<i>Gambar 3.5. Perbandingan MAPE per model (bar chart per target)</i>	15
<i>Gambar 3.6. Bar chart ablasi studi dengan rata-rata ΔMAPE per kelompok fitur .</i>	16
<i>Gambar 3.7. Prediksi ensemble total klaim - 17 bulan (Ags 2025-Des 2026)</i>	17
<i>Gambar 3.8. Empirical Coverage Rate Backtesting 9 Window (Nov 2024-Jul 202</i> <i>.....</i>	18
<i>Gambar 3.9. Prediksi per Kuartal 2026: Point Estimate vs P90 Cadangan &</i> <i>Frekuensi.....</i>	19

DAFTAR TABEL

<i>Tabel 1. Feature Engineering</i>	10
<i>Tabel 2. Statistik deskriptif klaim</i>	12
<i>Tabel 3. Perbandingan MAPE model pada walk-forward validation (5 fold).....</i>	15
<i>Tabel 4. Hasil ablasi studi ΔMAPE saat kelompok fitur dihapus.....</i>	16
<i>Tabel 5. Bobot ensemble per target (inverse MAPE weighting)</i>	16
<i>Tabel 6. Empirical Coverage Rate Prediction Interval</i>	18
<i>Tabel 7. Ringkasan prediksi 2026 per kuartal dengan P90 Cadangan</i>	18
<i>Tabel 8. Perbandingan 2025 Annualized vs Prediksi 2026</i>	Error! Bookmark not defined.
<i>Tabel 9. Rekomendasi cadangan teknis per kuartal 2026.....</i>	20
<i>Tabel L1. Prediksi lengkap 17 bulan - Agustus 2025 hingga Desember 2026.....</i>	24
<i>Tabel L2. Ringkasan konfigurasi model dan hyperparameter</i>	25

BAB I

PENDAHULUAN

1.1 Latar Belakang

Asuransi kesehatan individu berperan sentral dalam manajemen risiko keuangan, memberikan perlindungan terhadap pengeluaran medis tidak terduga. Di Indonesia, pertumbuhan basis nasabah terus meningkat seiring meningkatnya literasi masyarakat.

Namun industri menghadapi tantangan serius, yakni lonjakan klaim dengan pola kompleks yang tidak dapat diprediksi oleh metode konvensional, menimbulkan tekanan pada margin perusahaan dan keterjangkauan premi.

1.2 Rumusan Masalah

1. Faktor apa yang paling memengaruhi severitas (besaran nominal) klaim asuransi kesehatan individu?
2. Faktor apa yang paling memengaruhi frekuensi klaim asuransi kesehatan individu?
3. Bagaimana membangun model machine learning yang akurat untuk memprediksi tren frekuensi, severitas, dan total nominal klaim?
4. Model mana yang memberikan performa terbaik untuk prediksi time series klaim asuransi?
5. Bagaimana rekomendasi strategis bagi AXA Financial Indonesia berdasarkan hasil prediksi 2026?

1.3 Tujuan

1. Melakukan eksplorasi dan pembersihan data klaim secara komprehensif.
2. Mengidentifikasi faktor-faktor paling berpengaruh terhadap severitas dan frekuensi klaim.
3. Membangun dan mengevaluasi minimal dua model machine learning untuk prediksi tren klaim.
4. Menghasilkan prediksi klaim 17 bulan ke depan beserta rekomendasi actionable bagi AXA Financial Indonesia.

BAB II

METODOLOGI

2.1 Data

2.1.1 Sumber Data

Dataset bersumber dari AXA Financial Indonesia, disediakan khusus untuk kompetisi DSC MCF ITB 2026. Terdiri dari dua tabel:

1. Data Polis dengan 4.096 baris dan 6 kolom (Nomor Polis, Plan Code, Gender, Tanggal Lahir, Tanggal Efektif Polis, Domisili);
2. Data Klaim dengan 5.781 baris yang setelah pemfilteran status PAID menghasilkan 4.627 klaim valid dengan 13 kolom meliputi informasi klinis dan administratif lengkap.

Data mencakup periode klaim Januari 2024 - Juli 2025 (19 bulan observasi).

2.1.2 Preprocessing & Winsorisasi

Preprocessing meliputi beberapa tahapan:

1. Parsing tanggal dari format integer (YYYYMMDD) ke datetime;
2. Identifikasi missing values 37 baris pada Inpatient/Outpatient dan tanggal pembayaran, 6 baris pada ICD Diagnosis/Description, dan 7 baris pada lokasi RS;
3. 37 baris dengan nilai Inpatient/Outpatient dan tanggal pembayaran yang hilang dieksklusi hanya pada analisis yang membutuhkan kolom tersebut; jumlah dataset merged tetap utuh 4.627 baris. Tidak ada penghapusan permanen dari dataset;
4. Winsorisasi batas bawah 1% dan batas atas 99% pada level klaim individual, sebelum agregasi bulanan (rentang valid: Rp187.242 - Rp633.686.130) untuk mereduksi dampak outlier ekstrem tanpa menghilangkan data;
5. Merge Data Polis ke Data Klaim melalui Nomor Polis untuk enrichment demografis.

2.1.3 Feature Engineering

Feature engineering dilakukan dalam dua tahap. Pertama, pada level klaim individual:

1. kalkulasi Usia_Saat_Klaim, Length of Stay, Is_Outpatient, dan fitur musiman (Tahun, Bulan, Kuartal).
2. agregasi 19 bulan observasi menghasilkan 27 fitur yang dikelompokkan dalam lima kelompok sebagaimana ditunjukkan pada Tabel 1.

Kelompok	Fitur	Keterangan
Temporal	Time_Index, Month, Quarter	Indeks waktu dan kalender
Cyclical	Month_Sin, Month_Cos, Quarter_Sin, Quarter_Cos	Encoding siklus tanpa diskontinuitas
Lag	Freq/Sev/Total_Lag_1,2,3	Autokorelasi hingga 3 bulan
Rolling	Rolling_Mean/Std_3	Statistik bergilir 3 - 6 bulan
Exposure	Active_Polis	Anchor aktuarial importance 0% karena portofolio stabil 4.096 polis; dipertahankan untuk skenario portofolio berubah

Tabel 1. Feature Engineering

Jumlah fitur aktif per target: Frequency 12, Severity 12, Total Claim 11. Exposure dipertahankan untuk kompatibilitas aktuarial meski feature importance 0%.

2.2 Model yang Digunakan

Tim mengimplementasikan tiga model yang dikombinasikan dalam arsitektur ensemble:

- Prophet (Taylor & Letham, 2018): model time series additive dari Meta dengan konfigurasi `yearly_seasonality=False`, `seasonality_mode='additive'`, `changepoint_prior_scale=0.01`. Dipilih karena robust terhadap data pendek dan mampu menangkap tren non-linear secara otomatis.
- LightGBM (Ke et al., 2017): gradient boosting berbasis histogram dengan `n_estimators=200`, `learning_rate=0.05`, `max_depth=2`, `num_leaves=4`. Unggul dalam menangkap interaksi fitur lag dan rolling statistics pada data time series.
- Seasonal Naive: metode baseline yang menggunakan nilai dari periode yang sama pada siklus tahunan sebelumnya. Berfungsi sebagai anchor stabilitas jangka panjang dalam arsitektur ensemble.

2.3 Arsitektur Ensemble & Validasi

2.3.1 Walk-Forward Validation

Validasi walk-forward diterapkan dengan 5 fold (minimum 14 bulan data latih; Fold 1: Jan 2024 - Mar 2025 hingga Fold 5: Jun - Jul 2025) untuk mencegah data leakage.

2.3.2 Bobot Ensemble & Progressive Weighting

Bobot ensemble dihitung menggunakan inverse MAPE weighting per target model dengan MAPE lebih kecil mendapat bobot lebih besar, tanpa grid search.

Pada fase prediksi 17 bulan, arsitektur progressive weighting membagi horizon menjadi tiga zona yakni:

1. Zona ML (langkah 0-4) bobot ML 90%, Naive 10%;
2. Zona Balance (langkah 5-10): bobot ML menurun linear dari 90% ke 50%;
3. Zona Naive (langkah 11-16): bobot Naive meningkat hingga 80%

2.3.3 Metrik Evaluasi (MAPE)

MAPE dipilih karena mengukur akurasi secara proporsional (galat 10% pada klaim besar lebih berdampak daripada klaim kecil). Skor akhir = rata-rata MAPE_freq, MAPE_sev, dan MAPE_total.

2.3.4 Sensitivity Analysis Hyperparameter

Dua keputusan hyperparameter yang sebelumnya dipilih secara konservatif divalidasi secara empiris melalui Cell 4A.

CPS Prophet: nilai 0.01 terbukti optimal (selisih antar nilai 0,02-0,05%). Blending ratio Seasonal Naive (30/70, 50/50, 70/30) menghasilkan MAPE identik 4,79% model insensitif terhadap kedua pilihan ini.

2.3.5 Prediction Interval & Backtesting Coverage

Prediction interval dibangun menggunakan block bootstrap pada hybrid residual pool: OOS residual (3×) + IS residual (1×) = 34 poin, 17 blok, block_size=2, n=500 iterasi, menghasilkan 80% CI (P10 - P90). IS residual dihitung dengan bobot ensemble per-langkah (progressive weights) agar konsisten dengan metodologi forecasting.

BAB III

HASIL DAN PEMBAHASAN

3.1 Eksplorasi Data Analysis (EDA)

3.1.1 Distribusi Klaim

Seluruh 4.627 klaim dalam dataset berstatus PAID. Distribusi nominal bersifat right-skewed dengan mean Rp55,0 juta dan median Rp14,4 juta; nilai maksimum Rp2,2 miliar pada data mentah sebelum winsorisasi; setelah winsorisasi 1% - 99% diterapkan, batas valid adalah Rp187.242 - Rp633.686.130, mereduksi dampak outlier katastrofe dalam pemodelan. Komposisi metode pembayaran: Reimburse 58,8% dan Cashless 41,2%. Berdasarkan jenis layanan: Inpatient 48,8%, Outpatient 41,9%, ODC 6,1%, ODS 2,4%.


Statistik	Nilai	Statistik	Nilai
Total Klaim	4.627	Metode Reimburse	2.722 (58,8%)
Mean Nominal	Rp 55,0 juta	Metode Cashless	1.905 (41,2%)
Median Nominal	Rp 14,4 juta	Inpatient (IP)	2.258 (48,8%)
Maks Nominal	Rp 2,2 miliar	Outpatient (OP)	1.940 (41,9%)

Tabel 2. Statistik deskriptif klaim

3.1.2 Analisis Demografis


Tinjauan demografis mengungkap pola risiko yang signifikan. Distribusi gender nyaris setara: perempuan 2.327 klaim (50,3%) vs. laki-laki 2.300 klaim (49,7%). Meski rata-rata klaim laki-laki (Rp56,8 juta) sedikit lebih tinggi dari perempuan (Rp53,2 juta), uji Kruskal-Wallis menyatakan selisih tersebut tidak bermakna secara statistik ($H=1,23$; $p=0,268$).

Faktor usia menunjukkan pola yang sangat kuat dan signifikan ($H=190,42$, $p<0,001$): kelompok usia >60 tahun mendominasi dengan 2.251 klaim (48,7%), diikuti 46 - 60 tahun dengan 1.804 klaim (39,0%). Korelasi Spearman antara usia dan severitas menghasilkan $\rho=0,136$ ($p<0,001$), mengkonfirmasi hubungan positif antara usia dan besaran klaim. Berdasarkan plan code, M-002 mendominasi dengan 3.028 klaim (65,5%), signifikan secara statistik ($H=34,51$, $p<0,001$). Lokasi RS



Gambar 3.1. Boxplot nominal klaim per kelompok umur

Terdapat satu temuan yang menarik perhatian pada kelompok umur 46 - 60 tahun: meskipun memiliki jumlah klaim terbanyak kedua (1.804 klaim, 39% total), median nominal klaimnya justru terendah (Rp 3,1 juta) dibandingkan semua kelompok lainnya. Keanehan ini berpotensi mencerminkan efek seleksi underwriting yang menghasilkan segmen peserta dengan kondisi kesehatan relatif lebih baik, dominasi plan dengan limit lebih rendah, atau pola utilisasi yang lebih bersifat preventif. Perlu dicatat bahwa mean klaim kelompok ini tetap berada di angka Rp 35,8 juta (rasio mean/median = 11,5x), yang konsisten dengan tren usia dan mengindikasikan distribusi yang sangat right-skewed bukan keanehan data. Temuan ini direkomendasikan untuk investigasi lanjutan dengan analisis multivariat yang mengontrol variabel plan code, tipe layanan, dan diagnosis.




Gambar 3.2. Boxplot nominal klaim per tipe layanan (IP/ODC/ODS/OP)


3.1.3 Tren Bulanan

Data bulanan mencakup 19 observasi (Januari 2024 - Juli 2025). Frekuensi klaim per bulan berada di kisaran 208 - 302, dengan nilai rata-rata sekitar 243 klaim/bulan. Puncak frekuensi tertinggi tercatat pada Januari 2024 dengan 302 klaim, sementara total nilai klaim bulanan berfluktuasi Rp18,95 miliar. Titik terendah adalah Januari 2025 (<Rp10 miliar total) sebelum rebound di Februari 2025 (severitas Rp58,3 juta). Pola musiman klaim cenderung lebih tinggi di awal tahun (Q1).

Uji Kruskal-Wallis tipe layanan sangat signifikan ($H=789,72$, $p<0,001$): median Inpatient $9,94\times$ Outpatient; korelasi LoS-severitas $\rho=0,503$ ($p<0,001$).



Gambar 3.3. Tren frekuensi klaim bulanan (Jan 2024 - Jul 2025)



Gambar 3.4. Tren total klaim bulanan (Jan 2024 - Jul 2025)


3.2 Machine Learning Training

3.2.1 Perbandingan MAPE Per Model

Evaluasi walk-forward (5 fold) menunjukkan hasil mengejutkan: Seasonal Naive melampaui kedua model ML konsisten dengan karakteristik data 19 bulan di mana pola musiman tahunan menjadi sinyal dominan. Ensemble inverse MAPE mengoptimalkan keunggulan ketiga model, menghasilkan MAPE rata-rata 4,79%.

Model	MAPE Frekuensi	MAPE Severitas	MAPE Total	Rata-rata
Prophet	14,36%	16,15%	16,00%	15,50%
LightGBM	7,00%	7,25%	7,84%	7,36%
Seasonal Naive	5,23%	4,34%	3,82%	4,46%
Ensemble (Optimal)	6,76%	4,89%	2,72%	4,79%

Tabel 3. Perbandingan MAPE model pada walk-forward validation (5 fold)




Gambar 3.5. Perbandingan MAPE per model (bar chart per target)

3.2.2 Dampak Feature Engineering - Ablasi

Uji ablasi dilakukan dengan menghapus satu kelompok fitur secara bergantian, lalu mengukur kenaikan Δ MAPE dibanding model penuh. Fitur lag memberi dampak terbesar pada severitas (+4,57%) dan total klaim (+5,44%); fitur cyclical paling kritis untuk frekuensi (+5,59%). Menariknya, fitur exposure tidak berkontribusi (0,00%), sesuai stabilnya portofolio pada 4.096 polis.

Kelompok Fitur	Δ MAPE Frekuensi	Δ MAPE Severitas	Δ MAPE Total	Rata-rata
Temporal	+1,15%	+0,13%	+0,18%	+0,49%
Cyclical	+5,59%	+3,30%	+2,32%	+3,74%
Lag	+2,00%	+4,57%	+5,44%	+4,00%
Rolling	+3,18%	+0,36%	+5,05%	+2,86%
Exposure	0,00%	0,00%	0,00%	0,00%

Tabel 4. Hasil ablasi studi Δ MAPE saat kelompok fitur dihapus



Gambar 3.6. Bar chart ablasi studi dengan rata-rata Δ MAPE per kelompok fitur

3.2.3 Bobot Ensemble & Feature Importance

Skema inverse MAPE weighting menghasilkan bobot berbeda tiap target. Seasonal Naïve mendominasi karena MAPE validasinya terendah di semua target, dengan bobot tertinggi pada frekuensi (0,473) dan total klaim (0,580).

Target	Bobot Prophet	Bobot LightGBM	Bobot Naïve
Frekuensi	0,173	0,354	0,473
Severitas	0,144	0,320	0,536
Total Klaim	0,138	0,282	0,580

Tabel 5. Bobot ensemble per target (inverse MAPE weighting)

Permutation importance memperkuat studi ablasi: frekuensi didominasi Month_Sin (+4,20%), Freq_Std_3 (+3,12%), Month_Cos (+2,61%). Severitas: Sev_Lag_2 (+4,35%) dan Month_Cos (+3,79%). Total klaim: Total_Lag_2 (+5,61%) dan Total_Rolling_3 (+4,24%). Konsistensi antara ablasi dan permutation memperkuat keandalan interpretasi model.


3.2.4 Sensitivity Analysis Hyperparameter

Sensitivity analysis (Cell 4A) mengkonfirmasi CPS 0.01 sebagai optimal (selisih antar nilai hanya 0,02 - 0,05%); model tidak sensitif terhadap changepoint regularization. Ketiga blending ratio Seasonal Naive (30/70, 50/50, 70/30) menghasilkan MAPE identik 4,79% rasio tidak material dalam 19 bulan data.

3.3 Hasil Prediksi

3.3.1 Forecast 17 Bulan (Agustus 2025 - Desember 2026)

Model ensemble menghasilkan prediksi 17 bulan (Agustus 2025 - Desember 2026) dengan prediction interval 80% berbasis block bootstrap. P50 total klaim 2026 sebesar Rp143,49 miliar hampir identik dengan point estimate Rp143,00 miliar (selisih 0,3%), mengkonfirmasi bootstrap bersifat unbiased.




Gambar 3.7. Prediksi ensemble total klaim - 17 bulan (Ags 2025-Des 2026)

Prediction interval Total Claim 2026: **P10 = Rp132,34 miliar, P50 = Rp143,49 miliar, P90 = Rp149,11 miliar**, lebar 80% PI = Rp16,78 miliar. P90 digunakan sebagai acuan cadangan teknis konservatif berbasis data, menggantikan buffer persentase arbitrary.

3.3.2 Backtesting Empirical Coverage

Validasi empiris coverage dilakukan melalui 9 expanding window backtesting. Hasilnya: PI Total Claim mencapai coverage 88,9% melampaui target nominal 80%. Satu-satunya miss adalah Januari 2025, yang merupakan titik terendah historis terdokumentasi di EDA (anomali musiman ekstrem). PI Frequency dan Severity menunjukkan undercoverage 66,7% interval terlalu sempit untuk dua target ini akibat volatilitas residual yang lebih tinggi.



Gambar 3.8. Empirical Coverage Rate Backtesting 9 Window (Nov 2024-Jul 2025)


Target	n Window	Coverage 80% PI	Coverage 90% PI	Keterangan
Total Claim	9	88,9%	88,9%	Layak acuan cadangan aktuarial
Claim Frequency	9	66,7%	77,8%	Indikatif undercoverage
Claim Severity	9	66,7%	88,9%	Indikatif undercoverage

Tabel 6. Empirical Coverage Rate Prediction Interval

2.3.3 Ringkasan Prediksi 2026 per Kuartal

Kuartal	Rata-rata Frekuensi	Rata-rata Severitas	Total Klaim (Rp M)	P90 Cadangan (Rp M)
Q1 2026	227,8	Rp 49,18 juta	37,13	38,70
Q2 2026	228,9	Rp 49,90 juta	33,32	34,74
Q3 2026	237,3	Rp 50,37 juta	36,01	37,54
Q4 2026	248,5	Rp 48,08 juta	36,55	38,13
Total 2026	235,6	Rp 49,38 juta	143,00	149,11

Tabel 7. Ringkasan prediksi 2026 per kuartal dengan P90 Cadangan



Gambar 3.9. Prediksi per Kuartal 2026: Point Estimate vs P90 Cadangan & Frekuensi

3.3.4 Analisis Tren & Perbandingan 2025 vs 2026

Perbandingan secara terannualisasi antara data 2025 (7 bulan observasi Jan - Jul yang diekstrapolasi dengan faktor $\times 12/7$) dan proyeksi 2026 memperlihatkan kondisi portofolio yang secara umum cukup stabil.

Metrik	2025 Annualized	2026 Prediksi	Delta
Frekuensi	2.806,29 klaim	2.827,67 klaim	+0,8%
Rata-rata Severitas	Rp 50,93 juta	Rp 49,38 juta	-3,0%
Total Klaim	Rp 143,14 miliar	Rp 143,00 miliar	-0,1%

Tabel 8. Perbandingan 2025 Annualized vs Prediksi 2026

Seperti terlihat pada Gambar 3.9, total frekuensi klaim hanya meningkat tipis sebesar +0,8%, rata-rata severitas bahkan mengalami penurunan -3,0%, dan total nominal klaim nyaris tidak bergerak di angka -0,1%. Penurunan marginal pada severitas rata-rata ini konsisten dengan dampak proses winsorisasi dan karakteristik pola musiman, di mana klaim-klaim bernilai sangat tinggi tidak diperkirakan akan terkonsentrasi secara ekstrem pada tahun 2026.

Dari sudut pandang manajemen risiko, fluktuasi nilai klaim antar bulan perlu mendapat perhatian serius: November 2026 diproyeksikan menjadi puncak total klaim (Rp 13,33 miliar), sementara Januari 2026 menjadi titik terendah (Rp 10,78 miliar) dengan selisih mencapai 23,6% dalam rentang 10 bulan. Pola volatilitas musiman ini menggarisbawahi pentingnya memiliki cadangan klaim yang bersifat adaptif dan tidak semata-mata mengandalkan angka rata-rata tahunan.

BAB IV

PENUTUP

4.1 Kesimpulan

Simpulan utama penelitian ini:

1. Ensemble Prophet-LightGBM-Seasonal Naive mencapai MAPE 4,79%, mengungguli Prophet tunggal (15,50%), LightGBM (7,36%), dan Naive (4,46%) nilai tambah ensemble terletak pada sinergi komplementer ketiga model
2. Seasonal Naive menjadi komponen terkuat: data 19 bulan membuat pola musiman tahunan mendominasi sinyal prediktif.
3. Driver frekuensi: siklus bulanan (Month_Sin/Cos) dan lag (Freq_Lag_1,2,3). Driver severitas: lag (Sev_Lag_1,2) dan siklus. Exposure tidak berkontribusi, konsisten dengan portofolio yang stabil.
4. Usia (H=190,42), tipe layanan (H=789,72), dan plan code (H=34,51) merupakan faktor penentu severitas yang signifikan (semua $p < 0,001$). Median Inpatient $9,94 \times$ Outpatient.
5. Prediction interval Total Claim 2026 (80% PI: Rp132,34 - 149,11 miliar) divalidasi secara empiris dengan coverage 88,9% pada 9 window backtesting melampaui target nominal 80%. P90 = Rp149,11 miliar digunakan sebagai cadangan teknis berbasis data.

4.2 Saran

Empat rekomendasi strategis berbasis bukti kuantitatif untuk AXA Financial Indonesia:

4.2.1 Cadangan Teknis 2026

Model memprediksi total klaim 2026 sebesar Rp143,00 miliar (point estimate) dengan 80% Prediction Interval Rp132,34 - 149,11 miliar. Distribusi kuartalan tidak merata Q1 dan Q4 secara historis menunjukkan volatilitas lebih tinggi. Berbeda dengan pendekatan buffer arbitrary, cadangan teknis yang direkomendasikan mengacu pada P90 berbasis data sebagai batas atas konservatif.

Kuartal	Total Prediksi (Rp miliar)	Cadangan Disarankan (P90 +4.3%)
Q1 2026	37,13	38,70
Q2 2026	33,32	34,74
Q3 2026	36,01	37,54
Q4 2026	36,55	38,13
Total 2026	143,00	149,11

Tabel 9. Rekomendasi cadangan teknis per kuartal 2026

Cadangan P90 dihitung proporsional dari P90 total 2026 berdasarkan distribusi point estimate per kuartal. Selisih P90 vs point estimate sebesar Rp6,11 miliar (+4,3%) mencerminkan uncertainty forecast berbasis data. Coverage empiris 88,9% (Cell 6B) mengkonfirmasi PI Total Claim layak digunakan sebagai acuan. Peninjauan cadangan secara kuartalan menggunakan data aktual sangat dianjurkan.

4.2.2 Mitigasi Risiko Demografis

Kelompok >60 tahun mendominasi (2.251 klaim, median tertinggi). Diagnosis N18.0 (gagal ginjal) adalah penyebab klaim terbesar (~300 klaim, terkonsentrasi di segmen senior). Plan M-003 mencatat median klaim tertinggi.

- Terapkan underwriting selektif untuk peserta baru berusia >55 tahun dengan co-payment progresif atau sublimit untuk kondisi kronik tertentu.
- Kembangkan program disease management khusus untuk N18.0 mencakup monitoring rutin, edukasi gaya hidup, dan koordinasi perawatan.
- Lakukan review premi untuk profil risiko tinggi: peserta >60 tahun + Plan M-003 + metode Cashless.
- Pertimbangkan program wellness proaktif untuk kelompok 46-60 tahun sebagai investasi preventif.

4.2.3 Optimasi Biaya Layanan melalui Manajemen Length of Stay

LoS adalah prediktor terkuat severitas ($\rho=0,503$, $p<0,001$); median Inpatient $9,94 \times$ Outpatient ($H=789,72$, $p<0,001$); Cashless konsisten menghasilkan median klaim lebih tinggi dari Reimburse.

Audit klinis berbasis LoS perlu mendeteksi rawat inap >5 hari yang berpotensi diperpendek via protokol enhanced recovery. Clinical pathway per ICD utama (N18.0, C50, H26) dirumuskan sebagai acuan negosiasi RS rekanan. Pemantauan klaim Cashless Inpatient >Rp50 juta dan mekanisme second opinion untuk bedah elektif >Rp30 juta direkomendasikan.

4.2.4 Perencanaan Kapasitas Musiman

Data historis dan proyeksi 2026 konsisten menunjukkan pola musiman kuat: Januari sebagai puncak frekuensi (302 klaim) dan Q1/Q4 sebagai periode volume tertinggi dikonfirmasi oleh dominasi Seasonal Naive (MAPE 4,46%).

Penambahan kapasitas operasional pada periode Januari - Februari dan Oktober - November perlu disiapkan, baik melalui rekrutmen staf klaim kontrak maupun aktivasi overflow provider. Penerapan pre-authorization yang lebih ketat di bulan Desember juga disarankan guna meminimalkan klaim yang terbawa (carry-over) ke Januari, yang berpotensi memperparah lonjakan klaim awal tahun. Sebagai sistem deteksi dini, perlu dibangun early warning system berbasis ambang batas: apabila total klaim bulan berjalan melampaui proyeksi lebih dari 15%, maka review mingguan harus diaktifkan dan dilakukan eskalasi ke jajaran manajemen senior. Selain itu, negosiasi prioritas kapasitas tempat tidur dengan rumah sakit rekanan utama perlu dilakukan sejak awal tahun sebagai antisipasi terhadap bulan-bulan dengan volume klaim puncak.

4.3 Limitasi dan Pengembangan Ke Depan

Terdapat tiga keterbatasan utama: (1) Data historis hanya 19 bulan, terlalu singkat untuk menangkap siklus multi-tahun, terutama untuk proyeksi 17 bulan ke depan; (2) Pool residual 34 poin membatasi keandalan PI untuk Frequency dan Severity (coverage 66,7%), meski PI Total Claim mencapai 88,9%; (3) Faktor eksternal seperti inflasi biaya medis, perubahan regulasi, dan tren epidemiologi belum diintegrasikan ke dalam model.

Untuk pengembangan ke depan, tim merekomendasikan:

1. Ekspansi dataset ke 36-60 bulan untuk meningkatkan stabilitas model;
2. Integrasi fitur makro-ekonomi dan indeks inflasi biaya RS;
3. Pengembangan model individual-level untuk prediksi risiko per nasabah;
4. Implementasi model Bayesian atau conformal prediction untuk kuantifikasi uncertainty prediksi;
5. A/B testing rekomendasi intervensi preventif untuk mengukur efektivitas aktual di lapangan.

DAFTAR PUSTAKA

- Asosiasi Asuransi Jiwa Indonesia. (2024). Statistik Industri Asuransi Jiwa Indonesia. Jakarta: AAJI.
- Hyndman, R. J., & Athanasopoulos, G. (2021). *Forecasting: Principles and Practice* (3rd ed.). OTexts. <https://otexts.com/fpp3/>
- Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., & Liu, T. Y. (2017). LightGBM: A highly efficient gradient boosting decision tree. *Advances in Neural Information Processing Systems*, 30, 3146–3154. <https://proceedings.neurips.cc/paper/2017/hash/6449f44a102fde848669bdd9eb6b76fa-Abstract.html>
- Langenberger, B., Schulte, T., & Groene, O. (2023). The application of machine learning to predict high-cost patients: A performance-comparison of different models using healthcare claims data. *PLOS ONE*, 18(1), e0279540. <https://doi.org/10.1371/journal.pone.0279540>
- Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2020). The M4 Competition: 100,000 time series and 61 forecasting methods. *International Journal of Forecasting*, 36(1), 54–74. <https://doi.org/10.1016/j.ijforecast.2019.04.014>
- Petropoulos, F., Apiletti, D., Assimakopoulos, V., Babai, M. Z., Barrow, D. K., Taieb, S. B., & Ziel, F. (2022). *Forecasting: Theory and practice*. *International Journal of Forecasting*, 38(3), 705–871. <https://doi.org/10.1016/j.ijforecast.2021.11.001>
- Taylor, S. J., & Letham, B. (2018). Forecasting at scale. *The American Statistician*, 72(1), 37–45. <https://doi.org/10.1080/00031305.2017.1380080>
- Villarini, M., Bertini, I., De Sanctis, S., & Fabiani, G. (2023). Machine learning in forecasting motor insurance claims. *Risks*, 11(9), 164. <https://doi.org/10.3390/risks11090164>
- Yusof, U. K., Khalid, M. N. A., Hussain, A., & Shamsudin, H. (2021). Financial time series forecasting using Prophet. In F. Saeed, F. Mohammed, & A. Al-Nahari (Eds.), *Innovative Systems for Intelligent Health Informatics* (pp. 461-471). Springer. https://doi.org/10.1007/978-3-030-70713-2_45

LAMPIRAN

Lampiran A - Prediksi Lengkap Agustus 2025 - Desember 2026

Periode	Frekuensi	Severitas (Rp juta)	Total Klaim (Rp miliar)	Status
2025-08	235	51,23	11,549	Prediksi
2025-09	223	48,74	10,426	Prediksi
2025-10	248	48,56	12,951	Prediksi
2025-11	247	46,95	12,765	Prediksi
2025-12	222	45,89	10,201	Prediksi
2026-01	227	45,67	10,783	Proyeksi
2026-02	225	53,48	13,428	Proyeksi
2026-03	232	48,39	12,917	Proyeksi
2026-04	221	50,87	10,790	Proyeksi
2026-05	238	47,33	10,815	Proyeksi
2026-06	228	51,51	11,712	Proyeksi
2026-07	255	49,67	12,980	Proyeksi
2026-08	236	50,45	12,025	Proyeksi
2026-09	222	50,98	11,005	Proyeksi
2026-10	256	46,00	11,957	Proyeksi
2026-11	260	49,98	13,329	Proyeksi
2026-12	230	48,26	11,263	Proyeksi

Tabel L1. Prediksi lengkap 17 bulan - Agustus 2025 hingga Desember 2026

Lampiran B - Ringkasan Model & Hyperparameter

Model	Konfigurasi Utama	Fitur yang Digunakan
Prophet	yearly_seasonality=False, seasonality_mode='additive', changepoint_prior_scale=0.01, custom quarterly seasonality fourier_order=3.	ds (Periode_Klaim), y (target)
LightGBM	n_estimators=200, learning_rate=0.05, max_depth=2, num_leaves=4	12/12/11 fitur per target (Freq/Sev/Total)
Seasonal Naïve	rata-rata historis per bulan kalender (bukan Lag-12 murni)	Target bulan yang sama tahun prior
Ensemble	Inverse MAPE weighting + progressive weighting 3 zona	Output ketiga model di atas

Tabel L2. Ringkasan konfigurasi model dan hyperparameter